

Segmentação de Imagens Hiperespectrais Odontológicas com Unmixing Espectral

Ranulfo Mascari Neto

Departamento de Ciência da Computação
Universidade Federal de Lavras (UFLA)
Lavras, MG, Brasil
ranulfo.neto@estudante.ufla.br

Renato Ramos da Silva

Departamento de Computação Aplicada
Universidade Federal de Lavras (UFLA)
Lavras, MG, Brasil
renato.ramos@ufla.br

Abstract—This work investigates semantic segmentation of oral and dental hyperspectral images using spectral unmixing as a physical-spectral guidance signal. The proposed approach preserves the original masks as the only semantic supervision and uses abundance maps inside attention gates of a dense U-Net. The model combines an AUnet backbone with an internal unmixing branch that learns abundance maps and a spectral reconstruction objective. The abundance maps modulate the skip connections, allowing the decoder to use both spatial context and spectral-mixture information. Experiments on the ODSI-DB are restricted to a controlled single-image protocol and compare Unet, AUnet, and the proposed Unmixing-Attention U-Net (UAUnet). Within this restricted protocol, the results indicate that attention gates improve sensitivity over Unet and that unmixing-guided gates provide additional gains under the same evaluation setting.

RESUMO

Este trabalho investiga a segmentação semântica de imagens hiperespectrais orais e odontológicas usando *unmixing* espectral como sinal de guia físico-espectral. A proposta preserva as máscaras originais como única supervisão semântica e usa mapas de abundância dentro dos *attention gates* de uma U-Net densa. O modelo combina uma AUnet com um ramo interno de *unmixing* que aprende mapas de abundância e uma reconstrução espectral auxiliar. Os mapas de abundância modulam as conexões de salto, permitindo que o decodificador utilize contexto espacial e informação de mistura espectral. Os experimentos no ODSI-DB são restritos a um protocolo controlado de imagem única e comparam Unet, AUnet e a Unmixing-Attention U-Net proposta (UAUnet). Sob esse protocolo restrito, os resultados indicam que os gates melhoram a sensibilidade em relação à Unet e que gates guiados por *unmixing* fornecem ganhos adicionais na mesma configuração de avaliação.

I. INTRODUÇÃO

Imagens hiperespectrais têm sido investigadas em aplicações biomédicas por combinarem informação espacial e espectral em uma única aquisição. Em odontologia, essa característica é particularmente interessante porque tecidos e estruturas orais podem apresentar respostas de reflectância

distintas mesmo quando suas diferenças visuais em RGB são sutis. O ODSI-DB foi proposto como uma base pública de imagens espectrais orais e odontológicas, contendo imagens de reflectância e anotações de especialistas para apoiar aplicações de visão computacional em odontologia [1].

Apesar desse potencial, a segmentação semântica em bases odontológicas hiperespectrais permanece desafiadora. As máscaras disponíveis podem ser esparsas, incompletas ou concentradas em regiões de maior confiança visual, e a obtenção de anotações densas depende de conhecimento especializado. Esse cenário é especialmente crítico quando o modelo supervisionado aprende apenas a partir de pixels originalmente anotados, descartando regiões não anotadas que podem conter informação espectral consistente com as classes de interesse.

Este trabalho parte da hipótese de que o *unmixing* hiperespectral pode fornecer um guia físico-espectral para a segmentação odontológica. As anotações humanas são mantidas como única fonte de supervisão semântica, enquanto as abundâncias estimadas pelo ramo de *unmixing* são usadas para modular as conexões de salto de uma AUnet. Desse modo, a fusão entre codificador e decodificador é guiada por informação espectral interpretável, sem alterar o alvo supervisionado da tarefa. Assim, a contribuição principal é uma arquitetura de segmentação densa guiada por *unmixing*, alinhada à natureza espacial da segmentação odontológica.

II. TRABALHOS RELACIONADOS

O uso de imagens hiperespectrais em odontologia já foi explorado em trabalhos de segmentação e análise automática. Boiko et al. [2] aplicaram redes profundas a imagens hiperespectrais odontológicas para segmentar regiões e características clinicamente relevantes. Posteriormente, Garcia Pezraza Herrera et al. [3] avaliaram o ODSI-DB em diferentes configurações de entrada, comparando imagens RGB, cubos hiperespectrais e classificações baseadas apenas em pixels. Esses trabalhos mostram que a informação espectral pode beneficiar a segmentação, mas concentram a contribuição na entrada do segmentador. O presente trabalho usa a informação

espectral também dentro do próprio segmentador, por meio de *attention gates* guiados por mapas de abundância.

Como extensão arquitetural da U-Net, Oktay et al. [4] propuseram a Attention U-Net, que incorpora *attention gates* nas conexões de salto entre codificador e decodificador. Esses mecanismos usam informação contextual de escalas mais profundas para ponderar espacialmente as características propagadas pelos *skips*, reduzindo ativações em regiões menos relevantes antes da concatenação no decodificador. Diferentemente de abordagens de localização em múltiplos estágios, os autores integram os gates diretamente à U-Net, mantendo uma arquitetura de segmentação densa treinável de fim a fim. Essa ideia é particularmente pertinente em imagens médicas, nas quais estruturas pequenas, bordas sutis e regiões de fundo podem dificultar a recuperação de classes minoritárias.

No campo de *unmixing* hiperespectral, Bioucas-Dias et al. [5] apresentam uma visão ampla das abordagens geométricas, estatísticas e baseadas em regressão esparsa. A NMF é uma das formulações clássicas para esse problema, pois representa dados não negativos como combinação de componentes também não negativos [6]. Em modelos neurais, Palsson et al. [7] mostram como autoencoders podem ser estruturados para realizar *blind unmixing*, interpretando a representação latente como abundâncias e o decodificador como *endmembers*. Uma comparação crítica posterior de autoencoders para *unmixing* reforça que escolhas arquiteturais e restrições físicas são decisivas para a interpretabilidade do modelo [8].

Também há trabalhos recentes que conectam *unmixing* e segmentação em contextos biomédicos. Abdel Aziz et al. [9] defendem o uso de mapas de abundância para representar tecidos sobrepostos, evitando a limitação de máscaras binárias em pixels mistos. Essa perspectiva é adequada ao ODSI-DB porque pixels de transição entre tecidos podem carregar assinaturas espectrais mistas. O presente trabalho segue essa linha ao usar abundâncias como um sinal contínuo e auxiliar dentro do segmentador, sem convertê-las em rótulos discretos. A contribuição específica é acoplar esse sinal aos *attention gates* de uma U-Net, mantendo a saída densa por pixel e a supervisão semântica original.

III. REFERENCIAL TEÓRICO

Esta seção apresenta os fundamentos usados no trabalho: imagens hiperespectrais, *unmixing*, NMF, autoencoders, *attention gates* e segmentação densa guiada por abundâncias.

A. Imagens Hiperespectrais

Uma imagem hiperespectral registra, para cada pixel, um vetor com medidas em várias bandas do espectro eletromagnético. Diferentemente de uma imagem RGB, na qual cada pixel é descrito por três canais, uma imagem hiperespectral forma um cubo de dados com duas dimensões espaciais e uma dimensão espectral. Assim, um pixel não é apenas uma cor, mas uma assinatura espectral que descreve como a região observada responde em diferentes comprimentos de onda [5].

No contexto médico e biológico, essa representação é relevante porque a interação da luz com tecidos depende

de absorção, espalhamento, reflectância, transmitância e fluorescência. Esses processos estão relacionados à composição e à estrutura do tecido, incluindo a presença de cromóforos como hemoglobina, melanina e água, além de alterações morfológicas e fisiológicas associadas a diferentes condições clínicas [10]. Por isso, imagens hiperespectrais podem revelar diferenças que não aparecem claramente em imagens RGB, especialmente quando tecidos visualmente semelhantes apresentam respostas espectrais distintas.

Neste projeto, essa propriedade é explorada no ODSI-DB, uma base pública de imagens espectrais orais e odontológicas com anotações de especialistas [1]. Cada pixel da cavidade oral é tratado como um espectro de reflectância, e não apenas como uma intensidade RGB; por isso, a coerência entre assinaturas espectrais é central para guiar a fusão entre informação espacial e espectral no segmentador.

B. Unmixing Hiperespectral

Em imagens hiperespectrais, um pixel pode conter a contribuição de mais de um material ou tecido. Isso ocorre por limitações de resolução espacial, por misturas ópticas na superfície observada ou por transições entre regiões anatômicas. O *hyperspectral unmixing* busca decompor o espectro de cada pixel em dois elementos: *endmembers*, que representam assinaturas espectrais de referência, e abundâncias, que indicam a contribuição de cada *endmember* no pixel [5].

No modelo linear de mistura, a medição na banda espectral i de um pixel pode ser descrita por:

$$y_i = \sum_{j=1}^p \rho_{ij} \alpha_j + w_i,$$

em que ρ_{ij} representa a resposta espectral do *endmember* j na banda i , α_j é a abundância fracionária desse *endmember*, w_i representa ruído ou erro de modelagem, e p é o número de *endmembers*. Em forma vetorial, a mesma relação pode ser escrita como:

$$y = M\alpha + w,$$

em que $M = [m_1, m_2, \dots, m_p]$ é a matriz de mistura formada pelas assinaturas espectrais dos *endmembers*, α é o vetor de abundâncias e w representa a perturbação. Como as abundâncias representam frações, elas geralmente são submetidas às restrições:

$$\alpha_j \geq 0, \quad j = 1, \dots, p, \quad \sum_{j=1}^p \alpha_j = 1.$$

Ao organizar Q pixels de uma imagem em uma matriz $Y \in \mathbb{R}_+^{B \times Q}$, o modelo pode ser escrito de forma matricial como $Y \approx MA$, em que $M \in \mathbb{R}_+^{B \times p}$ contém os *endmembers* e $A \in \mathbb{R}_+^{p \times Q}$ contém as abundâncias. Para o projeto atual, essa decomposição tem duas funções. Primeiro, ela permite aprender assinaturas espectrais representativas das estruturas odontológicas presentes em uma imagem. Segundo, os mapas de abundância fornecem uma medida contínua de associação

entre cada pixel e cada componente espectral, o que é usado posteriormente para guiar os *attention gates* sem modificar os rótulos supervisionados.

C. Fatoração de Matrizes Não Negativas

A fatoração de matrizes não negativas, ou *Non-negative Matrix Factorization* (NMF), é uma técnica de decomposição que aproxima uma matriz de dados não negativa pelo produto de duas matrizes também não negativas. Dada uma matriz de dados V , a NMF busca uma reconstrução $\hat{V}$ dada por:

$$\hat{V} = HW,$$

em que H representa os componentes de base e W representa os pesos de cada componente na reconstrução das observações. Essa formulação é baseada na restrição de não negatividade, que favorece representações aditivas dos dados [6]. Quando aplicada ao *unmixing* hiperespectral, essa decomposição possui uma interpretação natural: os componentes de H podem ser associados aos *endmembers*, enquanto os valores de W podem ser interpretados como abundâncias desses componentes em cada pixel. Essa relação é particularmente adequada para imagens de reflectância, pois os dados observados, as assinaturas espectrais e as abundâncias possuem interpretação não negativa.

No projeto, a NMF não é usada como modelo final isolado. Ainda assim, ela fornece a base conceitual para interpretar o *unmixing* como uma decomposição de espectros em componentes e pesos. Essa interpretação é importante porque o autoencoder adotado também reconstrói a imagem a partir de uma representação latente não negativa: a camada latente representa abundâncias, enquanto o decodificador representa os *endmembers*.

Uma variação relevante para relacionar NMF e redes neurais é a NMF convexa. Nessa formulação, os componentes de base são restringidos a combinações das próprias observações da matriz de dados. A reconstrução passa a ser escrita como [11]:

$$\hat{V} = VW_1W_2.$$

Definindo $H := VW_1$ e $W := W_2$, essa expressão preserva a forma geral da NMF, isto é, $\hat{V} = HW$. A diferença é que, na NMF convexa, a matriz de base H não é estimada livremente: ela é obtida a partir da própria matriz V .

D. Autoencoders

Autoencoders são modelos neurais treinados para reconstruir sua própria entrada. Eles possuem uma etapa de codificação, que transforma o dado de entrada em uma representação latente, e uma etapa de decodificação, que reconstrói o dado original a partir dessa representação. Quando a dimensão latente é menor que a dimensão de entrada, o modelo aprende uma representação compacta dos dados.

No contexto de *unmixing* hiperespectral, Palsson et al. [7] formulam o uso de autoencoders a partir do modelo linear de mistura. Para um pixel x_p , o modelo assume:

$$x_p = Ms_p + n_p,$$

em que M é a matriz de *endmembers*, s_p é o vetor de abundâncias do pixel e n_p representa ruído. Considerando todos os pixels da imagem, essa relação pode ser escrita como:

$$X = MS + N.$$

Essa formulação impõe uma interpretação direta à arquitetura do autoencoder. O codificador G_E mapeia o espectro de entrada x_p para uma representação latente h_p , enquanto o decodificador G_D reconstrói o espectro a partir dessa representação:

$$\hat{x}_p = G_D(G_E(x_p)).$$

Como a reconstrução final deve obedecer ao modelo linear de mistura, o decodificador é restringido a uma transformação linear. Assim, a última camada latente deve ter dimensão igual ao número de *endmembers*; suas ativações são interpretadas como as abundâncias s_p , e os pesos do decodificador são interpretados como as colunas da matriz M , isto é, os espectros dos *endmembers*. Dessa forma, após o treinamento, o autoencoder realiza *blind unmixing*: estima simultaneamente mapas de abundância e assinaturas espectrais a partir da própria imagem.

Essa interpretação exige restrições compatíveis com o modelo físico de mistura. Em particular, as abundâncias devem satisfazer a restrição de não negatividade e, frequentemente, a restrição de soma unitária. O modelo adotado segue essa ideia por meio de um ramo interno de *unmixing*: o codificador estima mapas de abundância não negativos, a normalização por soma impõe uma interpretação fracionária por pixel, e o decodificador espectral reconstrói os espectros de reflectância a partir de *endmembers* latentes. Assim, a saída auxiliar do modelo não é apenas uma reconstrução, mas também um conjunto interpretável de mapas de abundância e *endmembers*.

Palsson et al. [7] destacam ainda que a função objetivo deve preservar a forma espectral. Por isso, o projeto utiliza a distância angular espectral (*Spectral Angle Distance* – SAD) como perda de reconstrução. Para um espectro observado x e sua reconstrução $\hat{x}$, a SAD é dada por:

$$\text{SAD}(x, \hat{x}) = \arccos \left(\frac{x^T \hat{x}}{\|x\|_2 \|\hat{x}\|_2} \right).$$

Essa medida compara a direção dos vetores espectrais, reduzindo a dependência de diferenças de escala e enfatizando a similaridade da assinatura espectral. No projeto, a SAD é usada como termo auxiliar de reconstrução no treinamento conjunto da U-Net guiada por *unmixing*, incentivando que as abundâncias usadas pelos gates mantenham coerência físico-espectral.

De forma complementar, a relação entre autoencoders não negativos e NMF fornece uma base teórica para essa interpretação. Quando um autoencoder é raso, linear, sem termos de viés, com ativações identidade e pesos não negativos, sua reconstrução pode ser escrita como:

$$\hat{V} = VW_{\text{enc}}W_{\text{dec}}.$$

Essa expressão tem a mesma forma da NMF convexa, com $W_1 = W_{\text{enc}}$ e $W_2 = W_{\text{dec}}$ [11]. Portanto, enquanto o trabalho de Palsson et al. fundamenta o uso de autoencoders para *unmixing* hiperespectral, essa equivalência ajuda a entender por que autoencoders não negativos podem ser interpretados como modelos próximos a fatorações matriciais. Essa interpretação, porém, depende das restrições impostas ao modelo: arquiteturas mais profundas, ativações não lineares ou outras estratégias de não negatividade aumentam a flexibilidade, mas reduzem a equivalência direta com a NMF.

E. Segmentação Semântica Hiperespectral

Segmentação semântica é a tarefa de atribuir uma classe a cada pixel da imagem. Em imagens hiperespectrais, essa tarefa pode explorar tanto a organização espacial da cena quanto a assinatura espectral de cada pixel. No ODSI-DB, as classes correspondem a regiões e estruturas odontológicas anotadas por especialistas, o que torna a segmentação dependente de informação local, contexto espacial e diferenças espectrais sutis entre tecidos.

O projeto utiliza uma arquitetura do tipo U-Net como segmentador supervisionado. A U-Net foi proposta para segmentação biomédica e combina uma trilha de contração, que extrai contexto, com uma trilha de expansão, que recupera resolução espacial, usando conexões entre níveis correspondentes da rede [12]. Aqui, essa arquitetura é aplicada diretamente aos cubos hiperespectrais odontológicos.

Essa etapa estabelece a tarefa final do trabalho: produzir máscaras semânticas a partir de imagens hiperespectrais odontológicas. O modelo espectral atua em paralelo ao segmentador, como guia contínuo para os *attention gates*.

F. Attention Gates em U-Net

A U-Net original reutiliza mapas de características do codificador por meio de conexões de salto. Essas conexões ajudam a recuperar detalhes espaciais perdidos nas etapas de subamostragem, mas propagam todos os padrões extraídos pelo codificador, inclusive respostas de fundo ou regiões pouco informativas. A Attention U-Net modifica esse ponto específico da arquitetura: antes da concatenação com o decodificador, cada *skip* é multiplicado por um mapa de atenção espacial aprendido [4].

Seja x_l o mapa de características vindo do codificador no nível l e g_l o sinal de contexto vindo do decodificador em escala compatível. O gate calcula coeficientes espaciais $\alpha_l \in [0, 1]$ a partir de uma forma aditiva de atenção:

$$\alpha_l = \sigma(\psi^T \text{ReLU}(W_x x_l + W_g g_l + b)),$$

em que W_x , W_g e ψ são projeções aprendidas, b representa termos de viés e σ é a função sigmoide. O mapa propagado pelo *skip* passa a ser:

$$\hat{x}_l = \alpha_l \odot x_l.$$

Desse modo, regiões consideradas relevantes pelo contexto do decodificador são preservadas, enquanto regiões menos informativas têm sua contribuição reduzida. No trabalho de Oktay et al. [4], essa operação é introduzida para aumentar a sensibilidade em estruturas anatômicas difíceis, sem exigir um detector de região de interesse separado. No presente trabalho, a mesma ideia é usada como uma ablação arquitetural: avaliar se filtrar as conexões de salto da U-Net hiperespectral melhora a segmentação no ODSI-DB antes de introduzir mecanismos espectrais adicionais.

G. Segmentação Guiada por Unmixing

Em uma imagem hiperespectral, o vetor espectral de um pixel pode ser interpretado como mistura de componentes latentes associados a materiais ou tecidos. Para segmentação semântica, essa interpretação pode ser usada como sinal auxiliar interno ao modelo. Neste trabalho, os mapas de abundância são mantidos como variáveis contínuas e usados para regular a fusão de características espaciais na U-Net. Assim, o *unmixing* atua como guia físico-espectral da arquitetura, enquanto a anotação humana continua definindo a supervisão semântica.

A abordagem proposta combina essa interpretação espectral com a natureza densa da segmentação. As abundâncias não definem a classe final do pixel; elas influenciam apenas a passagem de características nas conexões de salto. Dessa forma, a decisão semântica continua sendo feita pela U-Net, enquanto o *unmixing* fornece um indício físico-espectral sobre quais regiões do codificador devem ser preservadas com maior intensidade pelo decodificador.

IV. METODOLOGIA

A. Base de Dados e Pré-processamento

Os experimentos utilizam cubos de reflectância do ODSI-DB interpolados para $B = 170$ bandas igualmente espaçadas entre 450 nm e 950 nm. Seja

$$\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^N$$

o conjunto de imagens anotadas, em que $X_i \in \mathbb{R}_+^{B \times H_i \times W_i}$ representa o cubo de reflectância da imagem i e $Y_i \in \{0, 1\}^{C \times H_i \times W_i}$ representa a máscara multiclasse, com $C = 35$ classes odontológicas. Como as anotações do ODSI-DB não são necessariamente densas, define-se o conjunto de pixels originalmente rotulados por:

$$\Omega_i^L = \left\{ p \in \Omega_i : \sum_{c=1}^C Y_{i,c,p} = 1 \right\},$$

em que Ω_i é o domínio espacial da imagem i . Pixels fora de Ω_i^L não contribuem para a perda supervisionada da linha de base.

Para o treinamento do segmentador, a entrada interpolada é normalizada por vetores de média e desvio padrão pré-computados para cada banda. Na UAUnet, o mesmo cubo também alimenta o ramo de *unmixing*, cuja reconstrução é comparada contra a reflectância. A avaliação é feita apenas nos pixels anotados reservados para teste no protocolo de

imagem única; portanto, esse protocolo mede uma comparação controlada dentro de uma cena, e não generalização entre pacientes ou entre imagens.

B. Ramo de Unmixing da UANet

A UANet reportada recebe a imagem hiperespectral normalizada $X_i \in \mathbb{R}^{B \times H_i \times W_i}$ e estima internamente um conjunto de $P = 48$ mapas de abundância. O objetivo desse ramo não é classificar pixels, mas produzir um sinal físico-espectral auxiliar que possa guiar os *attention gates*. Primeiro, uma convolução 3×3 projeta as $B = 170$ bandas para $D = 64$ canais, seguida de normalização em lote e GELU:

$$F_i = \phi_{\text{emb}}(X_i).$$

Em seguida, um bloco leve de atenção no eixo dos canais e um codificador baseado em convoluções 1×1 estimam os logits de abundância, com dimensões $64 \rightarrow 32 \rightarrow 16 \rightarrow P$. Se $z_{p,q}$ é o logit do componente latente p no pixel q , as abundâncias são normalizadas para respeitar não negatividade e soma unitária:

$$a_{p,q} = \frac{|z_{p,q}|}{\max\left(\sum_{s=1}^P |z_{s,q}|, \epsilon\right)}.$$

$$a_{p,q} \geq 0, \quad \sum_{p=1}^P a_{p,q} \approx 1.$$

A reconstrução espectral auxiliar usa $R = 10$ variantes por *endmember*. Se $e_{p,r} \in \mathbb{R}^B$ é a variante r do componente p e $\gamma_{p,r,q}$ é o peso obtido por *softmax* entre variantes no pixel q , então a reconstrução do espectro desse pixel pode ser escrita como:

$$\hat{x}_q = \sum_{p=1}^P a_{p,q} \sum_{r=1}^R \gamma_{p,r,q} e_{p,r}.$$

Essa reconstrução força o ramo de *unmixing* a manter relação com os espectros de reflectância observados, em vez de se tornar apenas uma representação discriminativa livre. Nenhum componente latente é mapeado diretamente para uma classe odontológica; as abundâncias permanecem como variáveis contínuas que guiam a segmentação.

C. U-Net Guiada por Abundâncias

A trilha principal de segmentação é uma AUNet com a mesma estrutura básica da U-Net de referência: três blocos descendentes, três blocos ascendentes e duas conexões de salto usadas pelo decodificador. A diferença da versão guiada está no cálculo dos mapas de atenção dos *skips*. Para cada conexão de salto, calcula-se primeiro um gate puramente espacial, dependente do mapa do codificador x_l e do sinal do decodificador g_l :

$$\alpha_l^{\text{base}} = \sigma\left(\psi^T \text{ReLU}(W_x x_l + W_g g_l + b)\right).$$

Em paralelo, calcula-se um gate guiado por abundâncias, no qual o mapa de abundâncias A_i é redimensionado para a escala do *skip* e projetado para o mesmo espaço intermediário:

$$\alpha_l^{\text{guiado}} = \sigma\left(\psi^T \text{ReLU}(W_x x_l + W_g g_l + W_a A_i + b)\right).$$

Para manter a ablação próxima da AUNet e evitar que o guia espectral domine a segmentação no início do treinamento, os dois mapas são combinados de forma residual:

$$\alpha_l = (1 - \eta) \alpha_l^{\text{base}} + \eta \alpha_l^{\text{guiado}}, \quad \eta = 0,10.$$

O *skip* final é $\hat{x}_l = \alpha_l \odot x_l$. Nos experimentos, as abundâncias usadas pelos gates são destacadas do gradiente da perda semântica. Assim, a segmentação aprende com as máscaras humanas originais, enquanto o ramo de *unmixing* é orientado pela reconstrução espectral. Essa escolha preserva o caráter físico das abundâncias e reduz o risco de que elas se tornem apenas variáveis latentes discriminativas sem interpretação espectral.

D. Treinamento e Avaliação da Segmentação

A segmentação é realizada com modelos que recebem $B = 170$ canais de entrada e produzem 35 mapas de classe. A comparação metodológica deste artigo é restrita ao protocolo controlado de imagem única. A mesma imagem clínica é usada em todos os experimentos; para cada classe anotada, 1% dos pixels é reservado para treino, 1% para validação e o restante para teste. Essa escolha permite comparar os modelos sob o mesmo cubo hiperespectral, a mesma distribuição de pixels anotados e a mesma supervisão humana original.

Três modelos são avaliados. O primeiro é a Unet, uma U-Net densa usada como linha de base. O segundo é a AUNet, que preserva a estrutura da Unet, mas insere *attention gates* nas conexões de salto. O terceiro é a UANet, que mantém a mesma trilha U-Net com gates, mas adiciona o ramo de *unmixing* com variantes de *endmembers* descrito anteriormente para estimar abundâncias e usá-las como guia físico-espectral dos gates. Assim, a comparação isola duas perguntas: o efeito dos gates em relação à Unet e o efeito adicional do guia por abundâncias em relação à AUNet.

Como nem todos os pixels possuem anotação, a perda de segmentação é calculada apenas no conjunto de pixels rotulados da máscara humana original. Define-se:

$$\Omega_i^L = \left\{ p \in \Omega_i : \sum_{c=1}^C Y_{i,c,p} = 1 \right\}.$$

A função objetivo supervisionada por imagem é a entropia cruzada negativa ponderada por classe:

$$\ell_i = \frac{\sum_{p \in \Omega_i^L} w_{y_p} [-\log P(y_p | x_p)]}{\sum_{p \in \Omega_i^L} w_{y_p}}.$$

em que w_{y_p} é o peso da classe, y_p é o rótulo do pixel e $P(y_p | x_p)$ é a probabilidade prevista para a classe correta. No treinamento, a perda do lote é:

$$\mathcal{L}_{\text{seg}} = \frac{1}{|\mathcal{B}^+|} \sum_{i \in \mathcal{B}^+} \ell_i,$$

em que $\mathcal{B}^+$ é o subconjunto de imagens do lote que possuem ao menos um pixel anotado.

Unet e AUnet são treinadas apenas com $\mathcal{L}_{\text{seg}}$. Na UAUnet, a perda total combina a perda semântica com termos físico-espectrais associados ao ramo de *unmixing*:

$$\mathcal{L} = \mathcal{L}_{\text{seg}} + \lambda_{\text{sad}} \mathcal{L}_{\text{SAD}} + \lambda_{1/2} \mathcal{L}_{1/2} + \lambda_{\text{div}} \mathcal{L}_{\text{div}}.$$

O termo $\mathcal{L}_{\text{SAD}}$ é a distância angular espectral entre X_i e $\hat{X}_i$, $\mathcal{L}_{1/2}$ é uma penalização de esparsidade $L_{1/2}$ sobre as abundâncias, e $\mathcal{L}_{\text{div}}$ penaliza similaridade excessiva entre *endmembers*. Nos experimentos com UAUnet, foram usados $\lambda_{\text{sad}} = 0,01$, $\lambda_{1/2} = 0,001$ e $\lambda_{\text{div}} = 0,001$. Em todos os casos, a saída de segmentação é avaliada no mesmo conjunto de pixels de teste.

A avaliação é feita no conjunto de teste usando acurácia, sensibilidade, especificidade e acurácia balanceada. Para cada classe, as probabilidades previstas são binarizadas com limiar 0,5 nos pixels anotados, e as métricas são definidas por:

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN}, \quad \text{Sens} = \frac{TP}{TP + FN},$$

$$\text{Spec} = \frac{TN}{TN + FP}, \quad \text{BAcc} = \frac{\text{Sens} + \text{Spec}}{2}.$$

Os valores globais reportados nos resultados são médias por classe sobre as classes do conjunto de interesse que possuem pixels positivos no teste. Na imagem usada, esse subconjunto é formado por pele, mucosa oral, esmalte, gengiva inserida e cabelo. Classes ausentes no teste não entram nessas médias, para evitar que acurácia e especificidade sejam artificialmente infladas por verdadeiros negativos triviais.

V. RESULTADOS E DISCUSSÃO

Os resultados da Tabela I comparam Unet, AUnet e UAUnet no mesmo protocolo de imagem única. Todos os modelos usam a mesma imagem clínica, a mesma divisão 1%/1%/98% dos pixels anotados por classe e as mesmas máscaras humanas originais. Assim, as diferenças observadas são compatíveis com as mudanças arquiteturais avaliadas: inclusão de *attention gates* e, em seguida, uso de abundâncias como guia desses gates.

Tabela I
COMPARAÇÃO NO PROTOCOLO DE IMAGEM ÚNICA.

Modelo	Acc.	BAcc.	Sens.	Spec.
Unet	0,956	0,825	0,654	0,997
AUnet	0,958	0,851	0,703	0,998
UAUnet	0,964	0,884	0,771	0,998

A Figura 1 apresenta visualizações qualitativas das predições na mesma imagem usada no protocolo experimental.

Essas visualizações não substituem as métricas da Tabela I, mas permitem inspecionar a distribuição espacial dos erros e acertos dos três modelos.

AUnet melhora a acurácia balanceada de 0,825 para 0,851 e a sensibilidade de 0,654 para 0,703 em relação à Unet. Esse resultado é coerente com a proposta da Attention U-Net [4]: os gates atuam nas conexões de salto e reduzem a propagação de ativações menos relevantes, favorecendo a recuperação de pixels positivos em classes de interesse. A acurácia e a especificidade permanecem muito altas nos dois modelos, o que indica que a principal diferença aparece na capacidade de recuperar regiões anotadas, e não na rejeição de pixels negativos.

A UAUnet apresenta o melhor desempenho entre os três modelos, com acurácia balanceada de 0,884 e sensibilidade de 0,771. Em relação à AUnet, o ganho é de 0,034 em acurácia balanceada e 0,068 em sensibilidade. Em relação à Unet, o ganho acumulado é de 0,059 em acurácia balanceada e 0,117 em sensibilidade. Como a especificidade se mantém próxima de 0,998, o aumento de sensibilidade não ocorre à custa de uma queda expressiva na identificação de pixels negativos.

Esses resultados são compatíveis com a hipótese central do trabalho: abundâncias de *unmixing* podem ser úteis como guia contínuo dos *attention gates*. A Unet fornece a linha de base densa; a AUnet mostra o efeito de filtrar espacialmente os *skips*; e a UAUnet adiciona um critério físico-espectral a essa filtragem. Portanto, a melhoria da UAUnet neste ensaio sugere que a informação espectral da mistura de tecidos ajuda a decidir quais características do codificador devem ser preservadas pelo decodificador durante a segmentação.

A principal limitação metodológica é que o protocolo é restrito a uma única imagem. A divisão por pixels permite uma comparação controlada entre arquiteturas, mas não mede robustez entre pacientes, variação entre câmeras ou generalização para outras cenas do ODSI-DB. Assim, os resultados devem ser interpretados como uma evidência inicial de ablação, não como validação clínica ou estatística ampla da arquitetura.

VI. CONCLUSÃO

Este trabalho apresentou uma abordagem para segmentação de imagens hiperespectrais odontológicas no ODSI-DB usando *unmixing* espectral como guia interno de uma U-Net densa. A proposta preserva as máscaras humanas como única supervisão semântica e usa abundâncias e reconstrução espectral para modular os *attention gates* das conexões de salto.

No protocolo de imagem única, a comparação entre Unet, AUnet e UAUnet mostrou ganhos progressivos em acurácia balanceada e sensibilidade. AUnet melhorou a recuperação de pixels positivos em relação à Unet, e a UAUnet obteve o melhor resultado ao adicionar o guia físico-espectral de *unmixing* aos gates. A principal evidência metodológica é que, nesse ensaio controlado, abundâncias podem ser úteis como sinal contínuo de guia físico-espectral. Como trabalhos futuros, destacam-se a avaliação em múltiplas imagens e sujeitos, a análise quantitativa dos mapas de abundância, a inspeção dos



Figura 1. Visualização qualitativa das predições no protocolo de imagem única. O painel superior mostra a imagem RGB, a máscara humana anotada e as predições dos três modelos restritas aos pixels anotados. O painel inferior mostra as mesmas predições sobrepostas à imagem RGB. Todas as visualizações usam a mesma imagem clínica e as mesmas máscaras humanas originais.

mapas de gate e a investigação de formas adicionais de tornar o guia espectral mais interpretável.

REFERÊNCIAS

- [1] J. Hyttinen, P. Fält, H. Jäsberg, A. Kullaa, and M. Hauta-Kasari, “Oral and dental spectral image database—ODSI-DB,” *Applied Sciences*, vol. 10, no. 20, p. 7246, 2020.
- [2] O. Boiko, J. Hyttinen, P. Fält, H. Jäsberg, A. Mirhashemi, A. Kullaa, and M. Hauta-Kasari, “Deep learning for dental hyperspectral image analysis,” in *Proceedings of the 27th Color and Imaging Conference*, pp. 295–299, 2019.
- [3] L. C. Garcia-Peraza-Herrera, C. Horgan, S. Ourselin, M. Ebner, and T. Vercauteren, “Hyperspectral image segmentation: A preliminary study on the oral and dental spectral image database (ODSI-DB),” *arXiv preprint arXiv:2303.08252*, 2023.
- [4] O. Oktay, J. Schlemper, L. Le Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, “Attention u-net: Learning where to look for the pancreas,” in *Proceedings of the 1st Conference on Medical Imaging with Deep Learning*, 2018. arXiv:1804.03999.
- [5] J. M. Bioucas-Dias, A. Plaza, N. Dobigeon, M. Parente, Q. Du, P. Gader, and J. Chanussot, “Hyperspectral unmixing overview: Geometrical, statistical, and sparse regression-based approaches,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 5, no. 2, pp. 354–379, 2012.
- [6] D. D. Lee and H. S. Seung, “Algorithms for non-negative matrix factorization,” in *Advances in Neural Information Processing Systems 13*, pp. 556–562, MIT Press, 2001.
- [7] B. Palsson, J. Sigurdsson, J. R. Sveinsson, and M. O. Ulfarsson, “Hyperspectral unmixing using a neural network autoencoder,” *IEEE Access*, vol. 6, pp. 25646–25656, 2018.
- [8] B. Palsson, J. R. Sveinsson, and M. O. Ulfarsson, “Blind hyperspectral unmixing using autoencoders: A critical comparison,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 2022.
- [9] B. Abdel Aziz, N. Abdallah Saab, A. Raad, O. Assainova, M. Khalil, and M. El Bouz, “A promising contribution of hyperspectral unmixing for overlapped tissues segmentation using autoencoders,” in *2025 Eighth International Conference on Advances in Biomedical Engineering (ICABME)*, 2025.
- [10] G. Lu and B. Fei, “Medical hyperspectral imaging: A review,” *Journal of Biomedical Optics*, vol. 19, no. 1, p. 010901, 2014.
- [11] I. Egendal, R. Froberg Brøndum, M. Pelizzola, A. Hobolth, and M. Bøgsted, “On the relation between autoencoders and non-negative matrix factorization, and their application for mutational signature extraction,” *arXiv preprint arXiv:2405.07879*, 2024.
- [12] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, pp. 234–241, Springer, 2015.